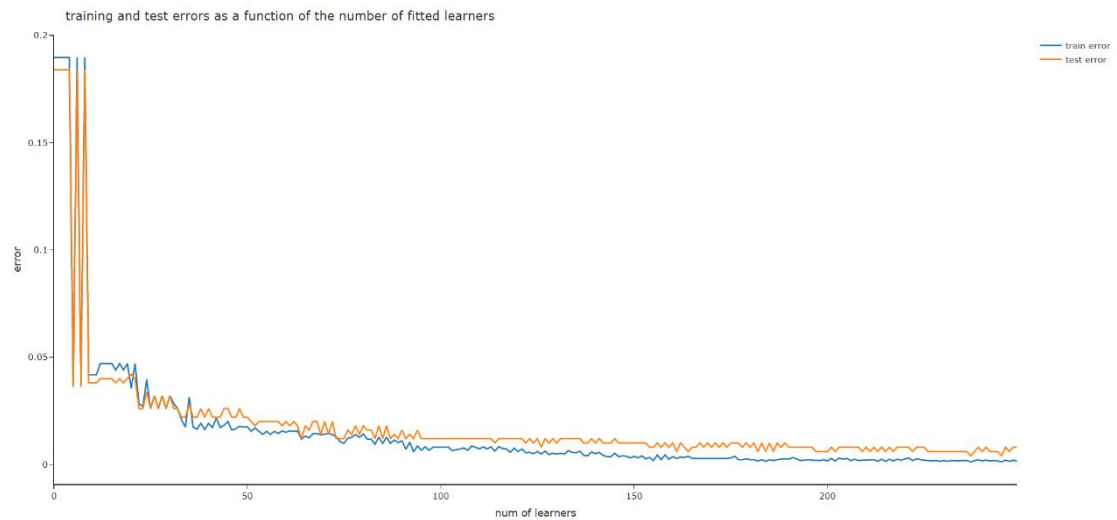


## חלק פרקטי:

## שאלה 1

: noise = 0

ניתן לראות שככל שנוסיף week learners ל adaboost השגיאה יורדת.

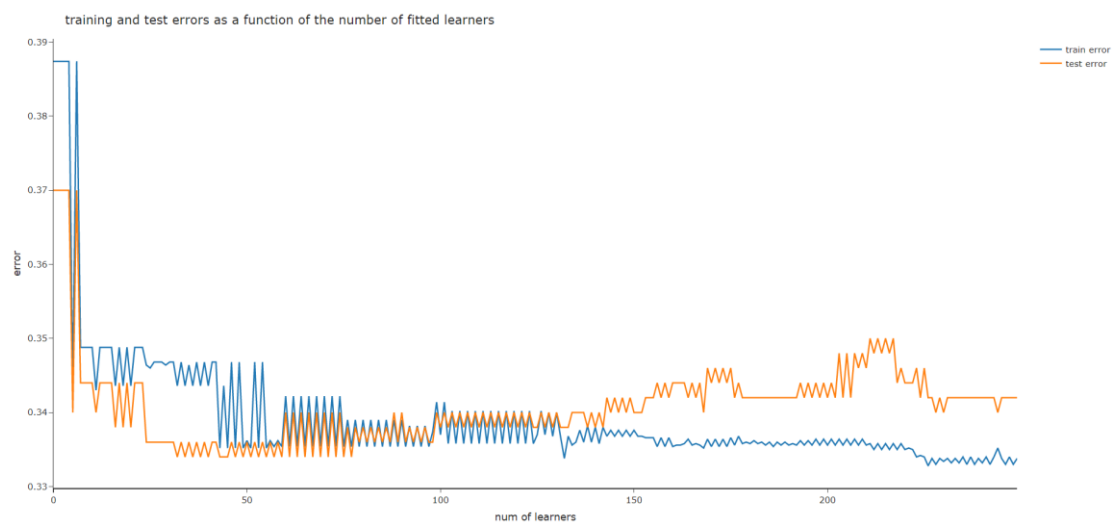


: noise = 0.4

ניתן לראות שבניגוד למקרה הקודם כשיש רעש כאשר יש יותר מידי לומדים נגיע ל overfit

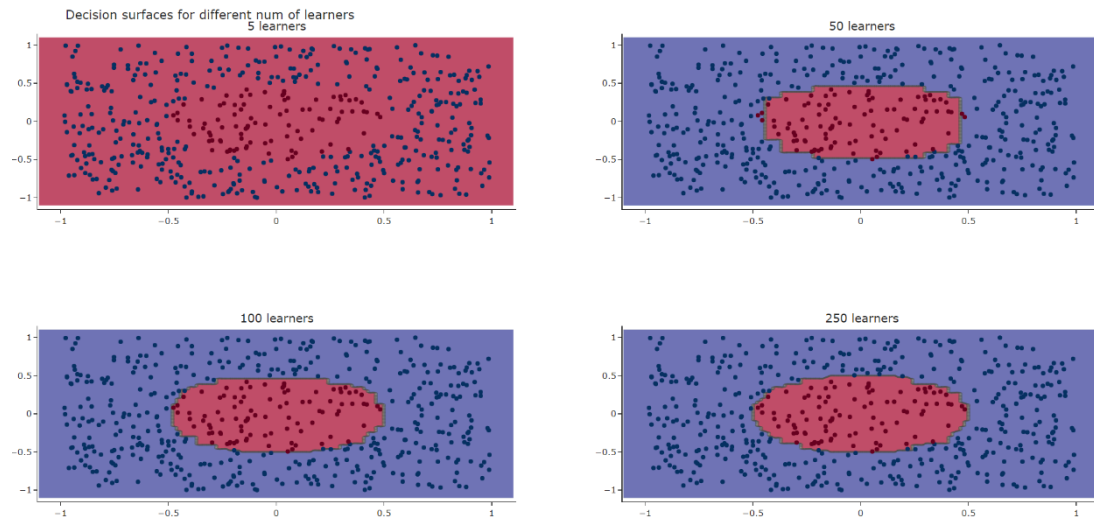
ניתן לראות זאת בגרף בכך שהחל משלב מסוים השגיאה על הטסט גדלה (והשגיאה על סט האימון נמוכה יותר)

ז"א שיש bias נמוך אבל variance גבוה.

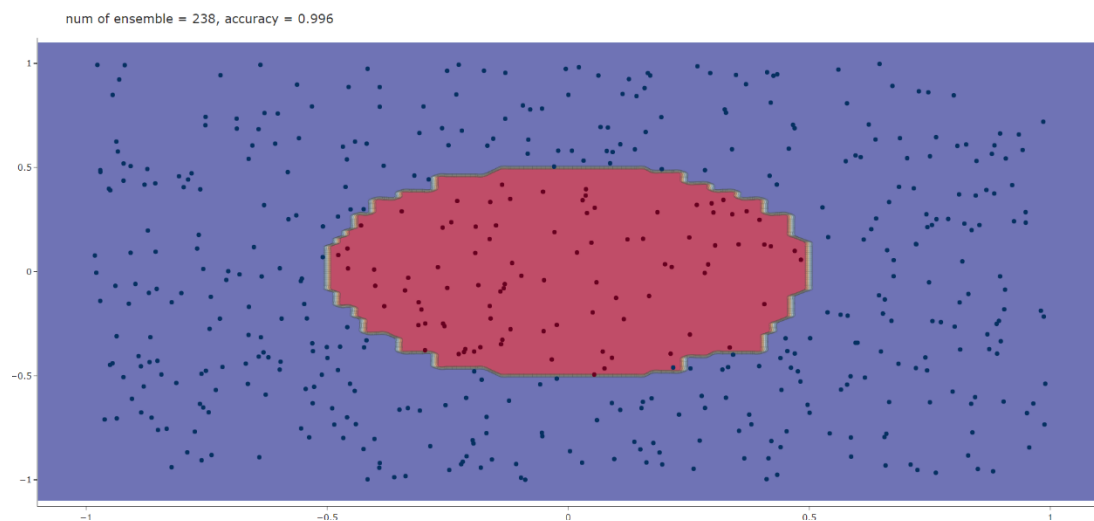


## שאלה 2

ניתן לראות שככל שיש יותר לומדים כך מספר הנקודות שנטעה בהן קטן.



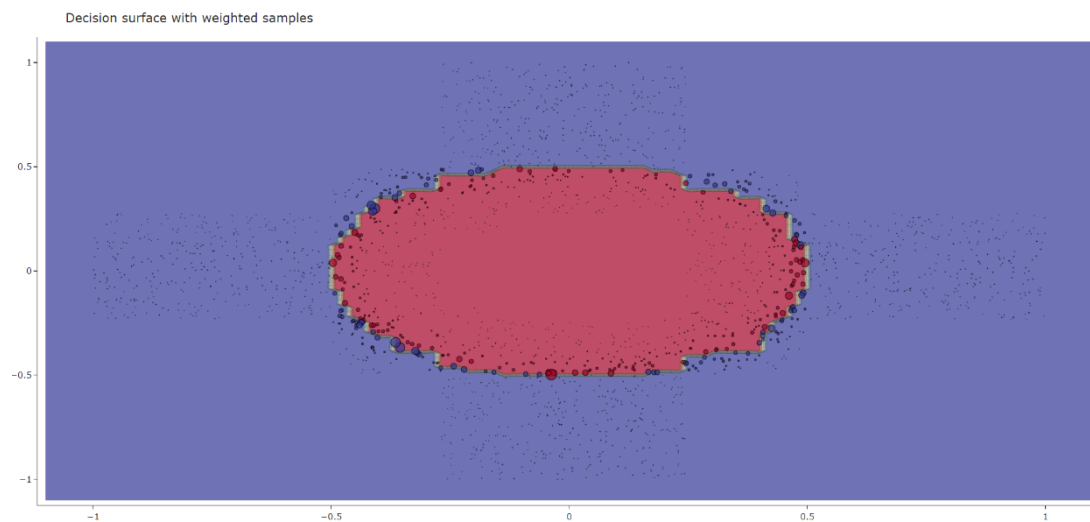
## שאלה 3



## שאלה 4


: noise = 0

ניתן לראות שהנקודות שהאלגוריתם התקשה בהן אלו נקודות על הגבול שבין הנקודות האדומות והכחולות  
ניתן לראות זאת מכך שהנקודות באיזורים האלו גדולות ומאיך שהגדרנו את הגודל (I) ניתן להבין כי  
האלגוריתם טעה בהן יותר מבשאר הנקודות.



: noise = 0.4

ניתן לראות שבניגוד למקרה הקודם כאשר יש רעש האלגוריתם טועה במידה שווה על נקודות בכל האזורים.



## 2.1 PAC Learnability

1. For  $\mathcal{A}$  some learning algorithm,  $\mathcal{D}$  a probability distribution over  $\mathcal{X}$  and the 0-1 loss function (i.e misclassification), prove the following are equivalent:

- (a)  $\forall \epsilon, \delta > 0 \exists m(\epsilon, \delta) \text{ s.t. } \forall m \geq m(\epsilon, \delta) \mathbb{P}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(\mathcal{A}(S)) \leq \epsilon] \geq 1 - \delta$   
 (b)  $\lim_{m \rightarrow \infty} \mathbb{E}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(\mathcal{A}(S))] = 0$

Hints:

- For (a)  $\Rightarrow$  (b) show that  $\forall \epsilon, \delta > 0$  and  $\forall m \geq m(\epsilon, \delta)$  it holds that  $\mathbb{E}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(\mathcal{A}(S))] \leq \epsilon + \delta$ .
- For (b)  $\Rightarrow$  (a) use Markov's inequality

כיון ראשון: (↑)

$$\lim_{m \rightarrow \infty} \mathbb{E}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(\mathcal{A}(S))] = 0$$

יהיו  $\epsilon, \delta > 0$  ונניח ש-

מאט מרקוב

$$\mathbb{P}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(\mathcal{A}(S)) \leq \epsilon] = 1 - \mathbb{P}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(\mathcal{A}(S)) > \epsilon] \geq 1 - \frac{\mathbb{E}[L_{\mathcal{D}}(\mathcal{A}(S))]}{\epsilon}$$

$$1 - \frac{\mathbb{E}[L_{\mathcal{D}}(\mathcal{A}(S))]}{\epsilon} \geq 1 - (1 - \delta) = \delta \quad \text{ש-כע-נראה}$$

נבחר  $m \geq m(\epsilon, \delta)$  מתקיים  $\mathbb{E}[L_{\mathcal{D}}(\mathcal{A}(S))] \leq \delta \epsilon$

ואכן בהינתן  $\lim_{m \rightarrow \infty} \mathbb{E}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(\mathcal{A}(S))] = 0$  - מההצבה נובע  $m \geq m_0$

מתקיים  $\lim_{m \rightarrow \infty} \mathbb{E}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(\mathcal{A}(S))] \leq \delta \epsilon$  עבור  $m \geq m_0$  (קבל)

מה שרצינו.

כיון שני: (↓)

ניבד לאנכי ש-  $\lim_{m \rightarrow \infty} \mathbb{E}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(\mathcal{A}(S))] = 0$  ז"ל הפערת הקבל

$$\forall \epsilon > 0 \exists m_0 \in \mathbb{N} \forall m > m_0 \mathbb{E}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(\mathcal{A}(S))] < \epsilon$$

כאשר נתון  $m \geq m(\epsilon, \delta)$  נובע  $P_{S \sim D^m}[L_D(A(S)) \leq \epsilon] \geq 1 - \delta$

$$E_{S \sim D^m}[L_D(A(S))] = \int_0^1 x \cdot P[L_D(A(S)) = x] dx \leq$$

$$\leq \int_0^{\frac{\epsilon}{4}} \frac{\epsilon}{4} \cdot P[L_D(A(S)) = x] dx + \int_{\frac{\epsilon}{4}}^1 x P[L_D(A(S)) = x] dx =$$

$$= \frac{\epsilon}{4} P[L_D(A(S)) \leq \frac{\epsilon}{4}] + P[L_D(A(S)) > \frac{\epsilon}{4}] = \frac{\epsilon}{4}(1 - \delta) + (1 - (1 - \delta))$$

$$= \frac{\epsilon}{4} + \frac{\delta \epsilon}{4}$$

אם נבחר  $\delta = \frac{\epsilon}{2}$  נקבל את הקצו

2. Let  $\mathcal{X} := \mathbb{R}^2$ ,  $\mathcal{Y} := \{0, 1\}$  and let  $\mathcal{H}$  be the class of concentric circles in the plane, i.e.,

$$\mathcal{H} := \{h_r : r \in \mathbb{R}_+\} \quad \text{where} \quad h_r(\mathbf{x}) = \mathbb{1}_{[\|\mathbf{x}\|_2 \leq r]}$$

Prove that  $\mathcal{H}$  is PAC-learnable and its sample complexity is bounded by

$$m_{\mathcal{H}}(\epsilon, \delta) \leq \frac{\log(1/\delta)}{\epsilon}$$

When proving, *do not* use a VC-Dimension argument. Instead prove the claim directly from the PAC learnability definition by showing a specific algorithm and analyzing its sample complexity.

Hint: Remember that for every  $\epsilon > 0$  it holds that  $1 - \epsilon \leq e^{-\epsilon}$

אנאליזה: קבוצת הנתונים  $S$  קרה דגימות על מרחב-קואורדינטות, נרצה לדחור

אל המעגל עם הרדיוס המקסימלי. שמקבל 1 - נהיה מאל ERM

פונקציה. אם נניחם האיסוף. כאשר  $f = h_r \in \mathcal{H}$

ומי  $S$  קרה דגימות הנבחרת דאכן נתן ונבחרת פשוט 0

(אחר את הרדיוס המקסימלי :

$$r_{\max} = \max_i \|x_i\| \quad (y_i = 1), \quad h_r^{\max} = \mathbb{1}_{\{\|x\| \leq r_{\max}\}}$$

כל יהי  $\epsilon, \delta$  (משקל אחד) המינימי של  $\epsilon$  ו- $\delta$  זה

מינימום של  $m$  המינימום של  $m$  שיהיה  $\epsilon$  של  $x_i$  לא קטן

א-ר המינימום של  $m$ :

$$P[L_{\epsilon, \delta}(h_r^{max}) > \epsilon] = P[\{ \forall i \in [m] : |\|x_i\| - r| > \epsilon \}] =$$

$$= P(|\|x_1\| - r| > \epsilon)^m = (1 - \epsilon)^m \leq e^{-\epsilon m}$$

$$\ln(e^{-\epsilon m}) \leq \ln(\delta) \iff -\epsilon m \leq \ln(\delta)$$

$$\iff m \geq \frac{\ln(\delta)}{\epsilon}$$

$$m_H(\epsilon, \delta) \leq \frac{\log(\delta)}{\epsilon}$$

## 2.2 VC-Dimension

3. Let  $\mathcal{X} = \{0, 1\}^n$  and  $\mathcal{Y} = \{0, 1\}$ , for each  $I \subseteq [n]$  define the parity function:

$$h_I(x) = \left( \sum_{i \in I} x_i \right) \bmod 2.$$

של  $(x_1, \dots, x_n)$  וקטור  $n$  תחזור את הפונקציה המקור

המכיל שלם 2-2.

יש  $2^n$  אפשרויות לחזור את  $I$  עקב  $2^n$  תתי קבוצות של  $[n]$

המקור סופי ובפרט  $|H_I| = 2^n$  וכן יש חסם תחת על  $VCdim$

$$VCdim(H_I) \leq \log(|H_I|) \leq \log(2^n) = n$$

נכוח שזהו שניון דרך של  $n$  קבוצות  $C$  ו- $n$   $|C| = n$

וגם  $H_2$  מתגבר את  $C$ .

נקודות:  $e_1, \dots, e_n$  וקטורי היחידה, וגם השמה  $y_1, \dots, y_n$

עבור הוקטורים האלו, גמיש את קבוצה  $I \subseteq \mathbb{R}$

מספיק בנקודה מסוימת  $h$  כך ש-  $h(e_i) = 1$  לכל  $i \in I$  כי לכל

$i \in I$  סביר הפאונדנטיות הוא 1 לכל  $i \notin I$  הסביר 0

$$h(e_j) = \begin{cases} 1 & j \in I \\ 0 & j \notin I \end{cases} \quad \text{פונקציה:}$$

4. Given an integer  $k$ , let  $([a_i, b_i])_{i=1}^k$  be any set of  $k$  intervals on  $\mathbb{R}$  and define their union  $A = \cup_{i=1}^k [a_i, b_i]$ . The hypothesis class  $\mathcal{H}_{k\text{-intervals}}$  includes the functions:  $h_A(x) := \mathbb{1}_{[x \in A]}$ , for all choices of  $k$  intervals. Find the VC-dimension of  $\mathcal{H}_{k\text{-intervals}}$  and prove your answer. Show that if we let  $A$  be any finite union of intervals (i.e.  $k$  is unlimited), then the resulting class  $\mathcal{H}_{\text{intervals}}$  has VC-dimension  $\infty$ .

נראה ש-  $\text{VCdim} \geq 2k$ . בואו קימנו קבוצה קטנה  $C$  ש-  $H_{k\text{-int}}|_C$  מתגבר

גמיש -  $C = \{c_1 < c_2 < \dots < c_{2k}\}$  קטע  $C$  וסדר את איברי  $C$  דסדר עליה

$H_{k\text{-int}}$  מתגבר על  $C$  כיוון כי יהי סיווג כלשהו של איברי  $C$

גמיש קל פשוט שאם  $i$  מקבל סיווג 1 בערך נכנסות אותו  $i$  קטע שמתחלף  $C$

עוד האינדוקציה אמרו לא לקבלו 1 - לא הסתם "הזרוע" דיוקרה הוא כלנסיון

דיוקרה  $0, 1, 0, 1, \dots$  ונקרא  $C$  מקטעים ונקל לכסיון עם  $C$  קטע

כעת נראה ש-  $\text{VCdim} \leq 2k+1$ : נהי  $|C| = 2k+1$  נסדר שוק דסדר עליה



כאשר (סוג) שגור האי-אמינות  $\delta$ . 1. נקרא סימול  $H_{k-inf}$  אל תנסה

י. וסוג אידיאלי עם 1 המאפיינים  $\delta$  א אידיאלי עם  $\delta$ .

למחשבה אם ניתן  $\delta$  -  $H$  להיות אידיאלי סופי. כלומר כלומר אל קבע  $\delta$

למא הערה  $\delta$  א - המינימל יהיה אינסופי.

### 2.3 Monotonicity

5. Let  $\mathcal{H}$  be a hypothesis class for a binary classification task. Suppose that  $\mathcal{H}$  is PAC learnable and its sample complexity is given by  $m_{\mathcal{H}}(\cdot, \cdot)$ . Show that  $m_{\mathcal{H}}$  is monotonically non-increasing in each of its parameters. That is:

- Show that given  $\delta \in (0, 1)$ , and given  $0 < \epsilon_1 \leq \epsilon_2 < 1$ , we have that  $m_{\mathcal{H}}(\epsilon_1, \delta) \geq m_{\mathcal{H}}(\epsilon_2, \delta)$ .
- Similarly, show that given  $\epsilon \in (0, 1)$ , and given  $0 < \delta_1 \leq \delta_2 < 1$ , we have that  $m_{\mathcal{H}}(\epsilon, \delta_1) \geq m_{\mathcal{H}}(\epsilon, \delta_2)$ .

• תהי  $\epsilon \in (0, 1)$  ויהי  $0 < \epsilon_1 \leq \epsilon_2 < 1$

על מנת  $m_{\mathcal{H}}(\epsilon_1, \delta) \geq m_{\mathcal{H}}(\epsilon_2, \delta)$  או שגור  $m_{\mathcal{H}}(\epsilon_1, \delta)$  כי קרוב

ל  $1 - \delta$  שוויון נקרא כל המאפיין  $\hat{h}$  עם שגיאה  $\epsilon_1$  אל היותר.

$$m \geq m_{\mathcal{H}}(\epsilon_1, \delta) \Rightarrow P[L_{D, \mathcal{H}}(\hat{h}) \leq \epsilon_1 \leq \epsilon_2] \geq 1 - \delta$$

אם נניח שגור  $m_{\mathcal{H}}(\epsilon_1, \delta) < m_{\mathcal{H}}(\epsilon_2, \delta)$  נקרא סטירה

למינימל  $m_{\mathcal{H}}(\epsilon_1, \delta)$  סידוריות המינימל.

גאוסן קומה ויהי  $\epsilon \in (0, 1)$  ו  $0 < \delta_1 \leq \delta_2 < 1$

$$m \geq m_{\mathcal{H}}(\epsilon, \delta_1) \Rightarrow P[L_{D, \mathcal{H}}(\hat{h}) \leq \epsilon] \geq 1 - \delta_1 \geq 1 - \delta_2$$



6. Let  $\mathcal{H}_1$  and  $\mathcal{H}_2$  be two classes for binary classification, such that  $\mathcal{H}_1 \subseteq \mathcal{H}_2$ . Show that  $VC - \dim(\mathcal{H}_1) \leq VC - \dim(\mathcal{H}_2)$ .

יהיו  $\mathcal{H}_1, \mathcal{H}_2$  2 מחלקות בינאריות כאלו  $\mathcal{H}_1 \subseteq \mathcal{H}_2$  קבוצה כלשהי

דוגמה  $\mathcal{H}_1 \subseteq \mathcal{H}_2$  נקרא  $\mathcal{H}_1$  מחלקת ארבעה  $\mathcal{H}_2$

אם  $\mathcal{H}_2$  מחלקת ארבעה  $\mathcal{H}_1$   $VC - \dim(\mathcal{H}_1) \leq VC - \dim(\mathcal{H}_2)$  נכון

בהיפוך  $\mathcal{H}_1$  מחלקת ארבעה  $\mathcal{H}_2$   $VC - \dim(\mathcal{H}_1) \geq |C|$  נכון

מחלקת ארבעה  $VC - \dim(\mathcal{H}_2) \geq |C|$

#### 2.4 Agnostic-PAC

7. Prove that if  $\mathcal{H}$  has the uniform convergence property with function  $m_{\mathcal{H}}^{UC} : (0, 1)^2 \rightarrow \mathbb{N}$ , then  $\mathcal{H}$  is Agnostic-PAC learnable with sample complexity  $m_{\mathcal{H}}(\epsilon, \delta) \leq m_{\mathcal{H}}^{UC}(\epsilon/2, \delta)$ .

אם  $\mathcal{H}$  -  $m_{\mathcal{H}}^{UC} : (0, 1)^2 \rightarrow \mathbb{N}$  הפונקציה  $m_{\mathcal{H}}^{UC}$  היא פונקציה

כזו  $\epsilon, \delta \in (0, 1)$  נכון  $m_{\mathcal{H}}(\epsilon, \delta) \leq m_{\mathcal{H}}^{UC}(\epsilon/2, \delta)$   $\mathcal{H}$  היא

$$D^m \left( \left\{ S \subseteq (X, Y)^m \mid \epsilon - \text{עצם } S \right\} \right) \geq 1 - \delta$$

אם  $n \in \mathcal{H}$  נכון  $\epsilon, \delta \in (0, 1)$   $m_{\mathcal{H}}(\epsilon, \delta) \leq m_{\mathcal{H}}^{UC}(\epsilon/2, \delta)$

אם  $\epsilon, \delta \in (0, 1)$  נכון  $|L_S(h) - L_D(h)| < \epsilon$   $\mathcal{H}$  היא

$$D^m \left( \left\{ S \subseteq (X, Y)^m \mid \frac{\epsilon}{2} - \text{עצם } S \right\} \right) \geq 1 - \delta$$

אם  $n \in \mathcal{H}$  נכון  $\epsilon, \delta \in (0, 1)$

$$|L_S(h) - L_D(h)| > \frac{\epsilon}{2} \Rightarrow -\frac{\epsilon}{2} < L_S(h) - L_D(h) < \frac{\epsilon}{2} \Rightarrow$$

$$L_D(h) \leq L_S(h) + \frac{\epsilon}{2} \quad \wedge \quad L_S(h) \leq L_D(h) + \frac{\epsilon}{2}$$

$$: (b) \quad h_D = \arg \min_{h \in H} L_D(h), \quad h_S = \arg \min_{h \in H} L_S(h) \quad \text{עבר}$$

$$L_D(h_S) \leq L_S(h_S) + \frac{\epsilon}{2} \leq L_S(h_D) + \frac{\epsilon}{2} \leq L_D(h_D) + \frac{\epsilon}{2} + \frac{\epsilon}{2} = L_D(h_D) + \epsilon$$

$$P_{S \sim D^m} (L_D(h_S) \leq \min_{h \in H} L_D(h) + \epsilon) \geq \quad : (b)$$

$$\geq D^m(\{S \in (\mathcal{X} \times \mathcal{Y})^m \mid \epsilon - \epsilon' - \delta\}) \geq 1 - \delta$$

$$m_H(\epsilon, \delta) \leq m^K(\frac{\epsilon}{2}, \delta) \quad \text{H} \quad \text{אגנוסטיק - PAC למידה} \quad \text{עם} \quad (a)$$

8. Let  $\mathcal{H}$  be a hypothesis class over a domain  $\mathcal{Z} = \mathcal{X} \times \{\pm 1\}$ , and consider the 0-1 loss function. Assume that there exists a function  $m_H$ , for which it holds that for every distribution  $\mathcal{D}$  over  $\mathcal{Z}$  there is an algorithm  $\mathcal{A}$  with the following property: when running  $\mathcal{A}$  on  $m \geq m_H$  i.i.d. examples drawn from  $\mathcal{D}$ , it is guaranteed to return, with probability at least  $1 - \delta$ , a hypothesis  $h_S : \mathcal{X} \rightarrow \{\pm 1\}$  with  $L_D(h_S) \leq \min_{h \in \mathcal{H}} L_D(h) + \epsilon$ . Is  $\mathcal{H}$  agnostic PAC learnable? Prove or show a counter example.

לא. (הקציה שהאגנוסטיקה) (יבחר דוגמה ל-D)

דוגמה נמצאת: H תהיה מה הפונקציות של איחוד ב האיחודים

המספרים הם קטעים שליליים 5 שמיני 5 ו-6 כמובן אינסופי

אכן הוא לא למידה PAC.

דוגמה בגלל D ו- H המוגדרת הנדומה אחידה

והי כל למידה - H כן שדוגמה X H נמצאת

הקטגוריה P - X יקבל ערך 1 - מטילים נבדל עם הסת P

נקבל 1 ומצויים את המצאה.

ח נא למד PAC כיו שיעור זלגלם S

אבל  $n$  מקימים  $L_D(h_S) \leq \min_{h \in H} L_D(h) + \epsilon$  כי אנחנו מסתמכים

על ההתפלגות האמיתית.

- התנאי המקימים אבל  $H$  לא למד PAC -  $\delta$  האנר שצריך.