

2.1 PAC Learnability

- For \mathcal{A} some learning algorithm, \mathcal{D} a probability distribution over \mathcal{X} and the 0-1 loss function (i.e misclassification), prove the following are equivalent:

$$(a) \forall \varepsilon, \delta > 0 \exists m(\varepsilon, \delta) \text{ s.t } \forall m \geq m(\varepsilon, \delta) \mathbb{P}_{S \sim \mathcal{D}^m}[L_{\mathcal{D}}(\mathcal{A}(S)) \leq \varepsilon] \geq 1 - \delta$$

$$(b) \lim_{m \rightarrow \infty} \mathbb{E}_{S \sim \mathcal{D}^m}[L_{\mathcal{D}}(\mathcal{A}(S))] = 0$$

Hints:

- For $(a) \Rightarrow (b)$ show that $\forall \varepsilon, \delta > 0$ and $\forall m \geq m(\varepsilon, \delta)$ it holds that $\mathbb{E}_{S \sim \mathcal{D}^m}[L_{\mathcal{D}}(\mathcal{A}(S))] \leq \varepsilon + \delta$.
- For $(b) \Rightarrow (a)$ use Markov's inequality

(1) : $\mathbb{E}_{S \sim \mathcal{D}^m}[L_{\mathcal{D}}(\mathcal{A}(S))] = 0$

$$\lim_{m \rightarrow \infty} \mathbb{E}_{S \sim \mathcal{D}^m}[L_{\mathcal{D}}(\mathcal{A}(S))] = 0 \quad \text{--- ה. ו. ו. } \varepsilon, \delta > 0 \quad \text{--- ה. ו. ו.}$$

בנימוק כרך נ

$$P_{S \sim \mathcal{D}^m}[L_{\mathcal{D}}(\mathcal{A}(S)) \leq \varepsilon] = 1 - P_{S \sim \mathcal{D}^m}[L_{\mathcal{D}}(\mathcal{A}(S)) > \varepsilon] \geq 1 - \frac{\mathbb{E}[L_{\mathcal{D}}(\mathcal{A}(S))]}{\varepsilon}$$

$$1 - \frac{\mathbb{E}[L_{\mathcal{D}}(\mathcal{A}(S))]}{\varepsilon} \geq 1 - (1 - \delta) = \delta \quad \text{--- ה. ו. ו.} \rightarrow \text{כזה}$$

$$\mathbb{E}[L_{\mathcal{D}}(\mathcal{A}(S))] \leq \delta \varepsilon \quad \text{ר. ו. ו. } m \geq m(\varepsilon, \delta) \quad \text{ה. ו. ו. ר. ו. ו.}$$

$$m \geq m_0 \text{ ס. } \mathbb{E}_{S \sim \mathcal{D}^m}[L_{\mathcal{D}}(\mathcal{A}(S))] = 0 \quad \text{ר. ו. ו.}$$

$$\text{לפ' } m(\varepsilon, \delta) = m_0 \text{ ר. ו. ו. } \mathbb{E}_{S \sim \mathcal{D}^m}[L_{\mathcal{D}}(\mathcal{A}(S))] \leq \varepsilon \delta \quad \text{ר. ו. ו.}$$

. ה. ו. ו.

(2) : $\mathbb{E}_{S \sim \mathcal{D}^m}[L_{\mathcal{D}}(\mathcal{A}(S))] = 0$

$$\text{לפ' } \mathbb{E}_{S \sim \mathcal{D}^m}[L_{\mathcal{D}}(\mathcal{A}(S))] = 0 \quad \text{--- ה. ו. ו.} \quad \mathbb{E}_{S \sim \mathcal{D}^m}[L_{\mathcal{D}}(\mathcal{A}(S))] \leq \varepsilon$$

$$\forall \varepsilon > 0 \quad \exists m_0 \in \mathbb{N} \quad \forall m > m_0 \quad \mathbb{E}_{S \sim \mathcal{D}^m}[L_{\mathcal{D}}(\mathcal{A}(S))] < \varepsilon$$

$$m \geq m(\epsilon, \delta) \text{ so } P_{S \sim D^m} [L_D(A(S)) \leq \epsilon] \geq 1 - \delta$$

$$\mathbb{E}_{S \sim D^m} [L_D(A(S))] = \int_0^1 x \cdot P[L_D(A(S)) = x] dx \leq$$

$$\leq \int_0^{\frac{\epsilon}{4}} \frac{\epsilon}{4} \cdot P[L_D(A(S)) = x] dx + \int_{\frac{\epsilon}{4}}^1 x P[L_D(A(S)) = x] dx =$$

$$= \frac{\epsilon}{4} P[L_D(A(S)) \leq \frac{\epsilon}{4}] + P[L_D(A(S)) > \frac{\epsilon}{4}] = \frac{\epsilon}{4}(1-\delta) + (1-(1-\delta))$$

$$= \frac{\epsilon}{4} + \frac{\delta \epsilon}{4}$$

$$(b3) \text{ so far } \delta = \frac{\epsilon}{2}$$

2. Let $\mathcal{X} := \mathbb{R}^2$, $\mathcal{Y} := \{0, 1\}$ and let \mathcal{H} be the class of concentric circles in the plane, i.e.,

$$\mathcal{H} := \{h_r : r \in \mathbb{R}_+\} \text{ where } h_r(\mathbf{x}) = \mathbb{1}_{\{||\mathbf{x}||_2 \leq r\}}$$

Prove that \mathcal{H} is PAC-learnable and its sample complexity is bounded by

$$m_{\mathcal{H}}(\epsilon, \delta) \leq \frac{\log(1/\delta)}{\epsilon}$$

When proving, do not use a VC-Dimension argument. Instead prove the claim directly from the PAC learnability definition by showing a specific algorithm and analyzing its sample complexity.

Hint: Remember that for every $\epsilon > 0$ it holds that $1 - \epsilon \leq e^{-\epsilon}$

ההנחתה שפונקציית ה-VC מוגדרת כפונקציית ה-VC של מינימיזציה של אמצעים.

ERM להלן מגדיר פונקציית ה-VC של מינימיזציה של אמצעים.

$f = h_r \in \mathcal{H}$ וקטור מינימיזציה של אמצעים רצוי. תכונה זו.

D. מינימיזציה של אמצעים מושגת על ידי מינימיזציה של אמצעים רצויים.

∴ מינימיזציה של אמצעים רצויים מושגת על ידי מינימיזציה של אמצעים רצויים.

$$r_{\max} = \max_i \|x_i\| \quad (y_i = 1) \quad , \quad h_r^{\max} = \mathbb{1}_{\{||x|| \leq \max_i \|x_i\|\}}$$

אנו מודים על ידי ϵ ו- δ את הטענה שקיים מני m ו-

ב- \mathbb{R}^n קיימים x_1, \dots, x_m כך ש- $\|x_i\| > r$ ו- $|h_r(x_i)| < \epsilon$.

$$P(\|x_i\| > r) < \delta$$

$$\begin{aligned} P\left[L_{D,r}\left(h_r^{\max}\right) \geq \epsilon\right] &= P\left[\left\{i \in [m] : |h_r(x_i)| > \epsilon\right\}\right] = \\ &= P(|\|x_i\| - r| > \epsilon)^m = (1 - \delta)^m \leq e^{-\epsilon m} \end{aligned}$$

$$\ln(e^{-\epsilon m}) \leq \ln(\delta) \iff -\epsilon m \leq \ln(\delta)$$

$$\iff m \geq \frac{\ln(\delta)}{-\epsilon}$$

$$m_H(\epsilon, \delta) \leq \frac{\log(\delta)}{-\epsilon}$$

2.2 VC-Dimension

3. Let $\mathcal{X} = \{0, 1\}^n$ and $\mathcal{Y} = \{0, 1\}$, for each $I \subseteq [n]$ define the parity function:

$$h_I(\mathbf{x}) = \left(\sum_{i \in I} x_i\right) \bmod 2.$$

הנחנו ש- h הוא פונקציית הסוג $h_I(\mathbf{x}_1, \dots, \mathbf{x}_n)$ ב-

. 2-2 מבחן גאוד

$[n]$ הוא אוסף של 2^n נקודות. H_I הוא אוסף של 2^n פונקציות.

VC dim H סגור מ- n כי $|h_I(\mathbf{x})| = 2^n$ גורם לכך ש-

$$\text{VC dim}(H_I) \leq \log(|H_I|) \leq \log(2^n) = n$$

$|I| = n$ \rightarrow $I \subseteq \{1, 2, \dots, n\}$ \Rightarrow $|I| \leq n$ \Rightarrow $n \leq |I| \leq n$

$\cup_{i=1}^k \cup_{j=1}^{3k+1} H_i$

y_1, \dots, y_n הינה אוסף נתונים מהצורה e_1, \dots, e_n וקטור

$I \subseteq [n]$ גודל הוקטור הינו $|I|$, ומייצג קבוצת

$\sum_{i \in I} h(e_i) = 1 - e$ מוגדר נספח

0 אם $j \notin I$ 1 אם $j \in I$

$$h(e_j) = \begin{cases} 1 & j \in I \\ 0 & j \notin I \end{cases}$$

4. Given an integer k , let $([a_i, b_i])_{i=1}^k$ be any set of k intervals on \mathbb{R} and define their union $A = \bigcup_{i=1}^k [a_i, b_i]$. The hypothesis class $\mathcal{H}_{k\text{-intervals}}$ includes the functions: $h_A(x) := \mathbb{1}_{[x \in A]}$, for all choices of k intervals. Find the VC-dimension of $\mathcal{H}_{k\text{-intervals}}$ and prove your answer. Show that if we let A be any finite union of intervals (i.e. k is unlimited), then the resulting class $\mathcal{H}_{\text{intervals}}$ has VC-dimension ∞ .

הנראה $H_{k\text{-int}}$ 2k היפר ניטר ניטר ניטר . VC dim $\geq 2k$ בזווית

$C = \{c_1 < c_2 < \dots < c_{2k}\}$ נניח שזו $c \in C$ $|C| = 2k$ -

c מתקיים $c_i < c < c_{i+1}$ $c \in H_{k\text{-int}}$

בנוסף dazu ש c מתקיים $c_i < c < c_{i+1}$ $c \in H_{k\text{-int}}$

בנוסף dazu ש c מתקיים $c_i < c < c_{i+1}$ $c \in H_{k\text{-int}}$

ולפיה c מתקיים $c_i < c < c_{i+1}$ $c \in H_{k\text{-int}}$

נניח c מתקיים $c_i < c < c_{i+1}$ $|C| = 2k+1$:

בנוסף ל $H_{k-\text{int}}$ -ה (המוגדר בה סעיף 1.5) נאמר ש H מתקיים בה הטענה.

לפיכך מתקיים $\delta_1 \leq \delta_2 \Rightarrow m_H(\varepsilon_1, \delta_1) \geq m_H(\varepsilon_1, \delta_2)$.

בה שown שה $m_H(\varepsilon, \delta)$ מתקיימת ה הטענה.

לה שה $m_H(\varepsilon, \delta)$ מתקיימת ה הטענה.

2.3 Monotonicity

5. Let \mathcal{H} be a hypothesis class for a binary classification task. Suppose that \mathcal{H} is PAC learnable and its sample complexity is given by $m_{\mathcal{H}}(\cdot, \cdot)$. Show that $m_{\mathcal{H}}$ is monotonically non-increasing in each of its parameters. That is:

- Show that given $\delta \in (0, 1)$, and given $0 < \varepsilon_1 \leq \varepsilon_2 < 1$, we have that $m_{\mathcal{H}}(\varepsilon_1, \delta) \geq m_{\mathcal{H}}(\varepsilon_2, \delta)$.
- Similarly, show that given $\varepsilon \in (0, 1)$, and given $0 < \delta_1 \leq \delta_2 < 1$, we have that $m_{\mathcal{H}}(\varepsilon, \delta_1) \geq m_{\mathcal{H}}(\varepsilon, \delta_2)$.

לה שה $\varepsilon_1 \leq \varepsilon_2 < 1$ מתקיימת ה הטענה.

לה שה $m \geq m_{\mathcal{H}}(\varepsilon_1, \delta)$ מתקיימת ה הטענה.

לה שה $m \geq m_{\mathcal{H}}(\varepsilon_1, \delta) \Rightarrow P[L_{D,n}(\hat{h}) \leq \varepsilon_1] \geq 1 - \delta$ מתקיימת ה הטענה.

$$m \geq m_{\mathcal{H}}(\varepsilon_1, \delta) \Rightarrow P[L_{D,n}(\hat{h}) \leq \varepsilon_1] \geq 1 - \delta$$

לה שה $m_{\mathcal{H}}(\varepsilon_1, \delta) < m_{\mathcal{H}}(\varepsilon_2, \delta)$ מתקיימת ה הטענה.

לה שה $m \geq m_{\mathcal{H}}(\varepsilon, \delta)$ מתקיימת ה הטענה.

לה שה $\delta_1 \leq \delta_2 \leq 1$ וה $\varepsilon \in [0, 1]$ מתקיימת ה הטענה.

$$m \geq m_{\mathcal{H}}(\varepsilon, \delta_1) \Rightarrow P[L_{D,n}(\hat{h}) \leq \varepsilon] \geq 1 - \delta_1 \geq 1 - \delta_2$$

6. Let \mathcal{H}_1 and \mathcal{H}_2 be two classes for binary classification, such that $\mathcal{H}_1 \subseteq \mathcal{H}_2$. Show that $VC - \dim(\mathcal{H}_1) \leq VC - \dim(\mathcal{H}_2)$.

ויל�ן היביר \subset מילא מושגון וילוחן 2 $\mathcal{H}_1, \mathcal{H}_2$ ית'

אם $C_{VC}(\mathcal{H}_1) < C_{VC}(\mathcal{H}_2)$ אז $\mathcal{H}_1 \subseteq \mathcal{H}_2$ מוגדר

$VC\dim(\mathcal{H}_1) \leq VC\dim(\mathcal{H}_2)$ כי $\mathcal{H}_1 \subseteq \mathcal{H}_2$ ית'

\mathcal{H}_2 מתקיימת $VC\dim(\mathcal{H}_1) \geq k$ אם $\mathcal{H}_1 \subseteq \mathcal{H}_2$ מתקיימת

$VC\dim(\mathcal{H}_2) \geq k$ מתקיימת

2.4 Agnostic-PAC

7. Prove that if \mathcal{H} has the uniform convergence property with function $m_{\mathcal{H}}^{UC} : (0, 1)^2 \rightarrow \mathbb{N}$, then \mathcal{H} is Agnostic-PAC learnable with sample complexity $m_{\mathcal{H}}(\epsilon, \delta) \leq m_{\mathcal{H}}^{UC}(\epsilon/2, \delta)$.

$m_{\mathcal{H}}^{UC}(0, 1)^2 \rightarrow N$ ית' אם קבוצה מסוימת מוגדרת כמייצגת \mathcal{H} מתקיימת

: מוגדר $X \times Y$ סעודי D מתקיים כדי $\epsilon, \delta \in (0, 1)$ כךže

$$D^m \left(\{S \subseteq (X \times Y)^m \mid \frac{|S \cap D|}{m} \geq \epsilon\} \right) \geq 1 - \delta$$

ריפרנס $h \in \mathcal{H}$ כךže מתקיים $L_s(h) \leq L_D(h) + \epsilon$

: בפ' $\epsilon, \delta \in (0, 1)$ כךže מתקיים $|L_s(h) - L_D(h)| < \epsilon$

$$D^m \left(\{S \subseteq (X \times Y)^m \mid \frac{|S \cap D|}{m} \geq \epsilon\} \right) \geq 1 - \delta$$

: מוגדר $h \in \mathcal{H}$ כךže

$$|L_s(h) - L_D(h)| > \frac{\epsilon}{2} \Rightarrow -\frac{\epsilon}{2} < L_s(h) - L_D(h) < \frac{\epsilon}{2} \Rightarrow$$

$$L_D(h) \leq L_S(h) + \frac{\varepsilon}{2} \quad \wedge \quad L_S(h) \leq L_D(h) + \frac{\varepsilon}{2}$$

: $\text{for } P(\cdot)$ $h_D = \arg \min_{h \in H} L_D(h), \quad h_S = \arg \min_{h \in H} L_S(h) \quad \text{true}$

$$L_D(h_S) \leq L_S(h_S) + \frac{\varepsilon}{2} \leq L_S(h_D) + \frac{\varepsilon}{2} \leq L_D(h_D) + \frac{\varepsilon}{2} + \frac{\varepsilon}{2} = L_D(h_D) + \varepsilon$$

$$\begin{aligned} P_{S \sim D^m} \left(L_D(h_S) \leq \min_{h \in H} L_D(h) + \varepsilon \right) &\geq \\ &\geq D^m \left(\{S \in (\mathcal{X} \times \mathcal{Y})^m \mid \varepsilon - \varepsilon^3 \leq S\} \right) \geq 1 - \delta \end{aligned} : \text{Pf}$$

$$m_H(\varepsilon, \delta) \leq m^*(\frac{\varepsilon}{2}, \delta) \quad \text{if } \varepsilon \cdot \log \frac{1}{\delta} - \text{PAC learning } H \quad \text{otherwise}$$

8. Let H be a hypothesis class over a domain $\mathcal{Z} = \mathcal{X} \times \{\pm 1\}$, and consider the 0-1 loss function. Assume that there exists a function m_H , for which it holds that for every distribution D over \mathcal{Z} there is an algorithm \mathcal{A} with the following property: when running \mathcal{A} on $m \geq m_H$ i.i.d. examples drawn from D , it is guaranteed to return, with probability at least $1 - \delta$, a hypothesis $h_S : \mathcal{X} \rightarrow \{\pm 1\}$ with $L_D(h_S) \leq \min_{h \in H} L_D(h) + \varepsilon$. Is H agnostic PAC learnable? Prove or show a counter example.

(D -> מתקיימת (בנוסף ל m^*) $m_H(\varepsilon, \delta) \leq m^*(\frac{\varepsilon}{2}, \delta)$) . 1.5

ההשערה היא: H הינה PAC נרחב אם ו רק אם $m_H(\varepsilon, \delta) \leq m^*(\varepsilon, \delta)$

ההשערה היא: V_C מוגדרת כפונקציית ה-VC של H ו $m_H \leq V_C + 5 \log(V_C + 1) + 5$

. PAC-learnability if and only if

$\exists \delta' \forall \varepsilon \exists N \forall D \Pr_{S \sim D}[\text{alg}(S) \text{ is } \varepsilon\text{-correct}] \geq 1 - \delta'$

ולכן $h_S \in \text{alg}(S)$ מתקיים $L_S(h_S) \leq L_D(h_S) + \varepsilon$

ולו $L_D(h_S) \leq \min_{h \in H} L_D(h) + \varepsilon$ - 1 $\Rightarrow L_D(h_S) \leq \min_{h \in H} L_D(h) + \varepsilon$

. כלומר $h_S \in \text{alg}(S)$ מתקיים $L_S(h_S) \leq \min_{h \in H} L_S(h) + \varepsilon$

א. קבוצת PAC בפונקציית f

ב. קבוצת PAC בפונקציית $L_D(h_s) \leq \min_{h \in H} L_D(h) + \epsilon$ מוגדרת כ' ϵ מוגדרת כ'

מ' הינה קבוצת PAC

- קבוצת PAC בפונקציית $L_D(h_s)$ מוגדרת כ' ϵ מוגדרת כ'